Universidad Nacional de Mar del Plata

Facultad de Ciencias Económicas y Sociales

Facultad de Ingeniería

ESPECIALIZACIÓN EN

Inteligencia de Datos

para la Gestión Estratégica



EXPLORACIÓN DE DATOS (E8102)

UNIDAD II. VARIABLE ALEATORIA

Modelado Probabilístico y Análisis Estadístico

- Conceptos Introductorios de Variable Aleatoria (V.A.)
- Clasificación: Categóricas vs. Cuantitativas
- Funciones de Probabilidad y Distribución (Discretas y Continuas)
- Medidas Características: Operador Momento Absoluto y Centrado
- Medidas de Posición (Esperanza), Variabilidad (Varianza, CV) y Forma (Asimetría, Kurtosis)
- Estandarización de Variables Aleatorias (z-scores)

NIVEL Y ASIGNATURA

Carrera de Especialización en Inteligencia de Datos para la Gestión Estratégica

Asignatura: Exploración de Datos (E8102)

EQUIPO DOCENTE

- **Esp. Mariano Morettini**
- **Dr. Lautaro Di Bártolo**

CONCEPTOS INTRODUCTORIOS

La asignación probabilística transforma atributos en modelos cuantitativos

1. Definición Formal de Variable Aleatoria (V.A.)

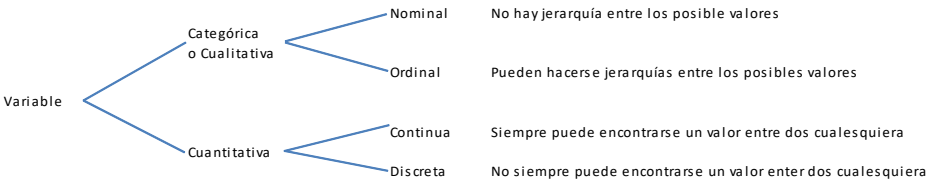
Una variable es una característica, atributo o condición de un objeto o persona que admite diferentes valores. Es ALEATORIA cuando puede asignarse una probabilidad de ocurrencia a cada uno de sus valores posibles.

2. Clasificación Fundamental

• Categóricas / Cualitativas: Se asignan etiquetas lingüísticas a los valores (ej: estado de un componente, nivel educativo).
• Cuantitativas: Se asigna un número a cada valor posible (ej: cantidad de puntos, tiempo de proceso, ingresos).

3. Protocolo de Definición de una V.A.

Definir una V.A. implica de forma estricta:
a) Identificar los distintos valores posibles que puede tomar (Xi).
b) Asignar una probabilidad de ocurrencia (pi) a cada valor.
c) Calcular la probabilidad acumulada (pa = P(X <= Xi)).



Caso de Estudio: Suma de Puntos al Arrojar 2 Dados

Espacio muestral total S = 36 resultados equiprobables. La V.A. cuantitativa discreta X suma los puntos obtenidos:

Valor (Xi)	Probabilidad (pi)	Acumulada (pa)
2	1 / 36	1 / 36
3	2 / 36	3 / 36
4	3 / 36	6 / 36
5	4 / 36	10 / 36
6	5 / 36	15 / 36
7	6 / 36	21 / 36
8	5 / 36	26 / 36
9	4 / 36	30 / 36
10	3 / 36	33 / 36
11	2 / 36	35 / 36
12	1 / 36	36 / 36 (1.00)

VARIABLES ALEATORIAS DISCRETAS

Los bastones y la función escalonada caracterizan la distribución discreta

Estructura Funcional Discreta

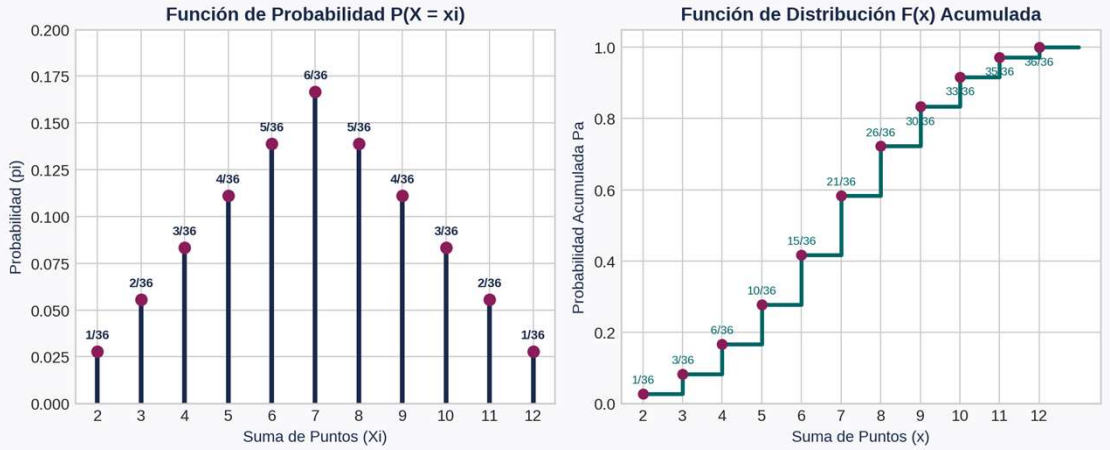
1. Función de Probabilidad Puntual P(X = xi)

• Se representa gráficamente mediante 'BASTONES'.
• La altura de cada bastón equivale a la probabilidad exacta pi de ese valor.
• Entre dos valores consecutivos, la probabilidad es estrictamente CERO (P(X = x) = 0 para x no perteneciente a {Xi}).

2. Función de Distribución Acumulada F(x)

• Gráficamente presenta forma ESCALONADA (acumulativa a la derecha).
• Propiedad Fundamental: La altura de cada 'ESCALÓN' en F(x) es exactamente igual a la altura del 'BASTÓN' correspondiente en P(X = xi).
• F(x) = P(X <= x) = Suma(pi para xi <= x).

Demostración Gráfica: Nótese en la figura adyacente cómo cada escalón acumula la masa de probabilidad puntual de la V.A.



VARIABLES ALEATORIAS CONTINUAS

El área bajo la curva de densidad mide la probabilidad en soporte continuo

Cálculo Integral en Variables Continuas

1. Función de Densidad de Probabilidad f(x)

• En el eje Y NO se grafica la probabilidad puntual, sino la ordenada matemática de densidad f(x).
• La probabilidad puntual en un único número continuo es cero: P(X = c) = 0.

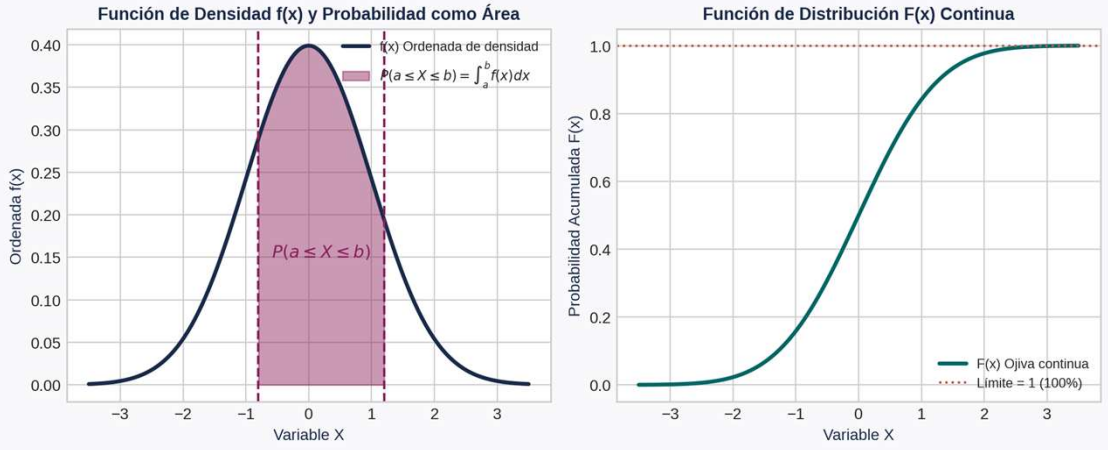
2. Probabilidad como Área Bajo la Curva

Para hallar la probabilidad de que X tome valores en el intervalo [a, b], se calcula la integral definida:

P(a <= X <= b) = Integral_a^b f(x) dx

3. Condición de Normalización u Ojiva F(x)

• Certeza total en el soporte: Integral_MIN^MAX f(x) dx = 1 (100%).
• Función de Distribución F(x) ('Ojiva'): Curva continua suave y monotónicamente creciente que va de 0 a 1.



MEDIDAS CARACTERÍSTICAS: MOMENTOS

Los momentos absolutos y centrados formalizan analíticamente la distribución

Concepto de Momento

Los MOMENTOS son operadores matemáticos fundamentales que vinculan los valores que puede tomar la V.A. con sus respectivas probabilidades de ocurrencia.

Permiten derivar sintéticamente la posición, dispersión, asimetría y curtosis de la distribución.

Propiedad de Orden (s):
La potencia a la que se elevan los valores (o desvíos) define el orden del momento.

Momentos Absolutos (ms)

Se calculan directamente sobre los valores Xi de la variable aleatoria.

Fórmula Genérica:

$$m_s = \sum X_i^s pi$$

- Orden 1 (m1):
  $m_1 = \sum X_i^1 pi$ = E(X)
  --> Esperanza Matemática
- Orden 2 (m2):
  m2 = $m_2 = \sum X_i^2 pi$
  --> Requerido para la Varianza
- Orden 3 (m3):
  m3 = $m_3 = \sum X_i^3 pi$

Momentos Centrados (μs)

Se calculan sobre los desvíos entre los valores y la Esperanza: xi = Xi - E(X).

Fórmula Genérica:

$$\mu_s = \sum x_i^s pi$$

- Orden 1 (μ1):
  $\mu_1 = \sum x_i^1 pi$ = 0 (Siempre)
- **Orden 2 (μ2):**
  $\mu_2 = \sum x_i^2 pi$ **= Varianza $\sigma^2(X)$**
- Orden 3 (μ3):
  $\mu_3 = \sum x_i^3 pi$ --> Requerido para Asimetría
- Orden 4 (μ4):
  $\mu_4 = \sum x_i^4 pi$ --> Requerido para Kurtosis

MEDIDA DE POSICIÓN

La Esperanza E(X) representa el promedio a priori y centro de gravedad

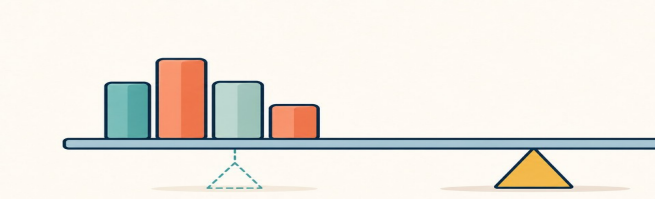
Esperanza Matemática E(X) — Primer Momento Absoluto (m1)

- **Formulación Discreta: E(X) = m1 =** $\sum X_i pi$
- **Formulación Continua: E(X) =** $\int_{MIN}^{MAX} X * f(x) dx$

Interpretación Clave: La Esperanza es un promedio 'A PRIORI'. Es el valor promedio que se obtendría si el experimento aleatorio se repitiera un número muy grande de veces. En física equivale al CENTRO DE GRAVEDAD de la distribución, y en juegos de azar representa el valor de la APUESTA EQUITATIVA.

Propiedades Fundamentales de E(X)

1. E(K) = K (La esperanza de una constante K es la constante).
2. E(K * X) = K * E(X) (Las constantes multiplicativas salen fuera).
3. E(X + K) = E(X) + K (Las constantes aditivas desplazan la esperanza).
4. E(X + Y) = E(X) + E(Y) (Linealidad de la suma de variables aleatorias).
5. Acotación: MIN <= E(X) <= MAX (Siempre dentro del soporte).



Ejemplo Ilustrativo y Consideraciones Técnicas

Caso Lanzamiento de un Dado Equilibrado:
Xi pertenece a {1, 2, 3, 4, 5, 6}, cada uno con pi = 1/6.
E(X) = 1*(1/6) + 2*(1/6) + 3*(1/6) + 4*(1/6) + 5*(1/6) + 6*(1/6) = 3.50 puntos.

Conclusiones Doctrinarias de Posgrado:

- **La E(X) puede tomar un valor que la V.A. NUNCA asume en la realidad (ningún dado saca 3.50).**
- **Unidad de medida: Es idéntica a la de la V.A. original (puntos, pesos, metros). NO ES UNA PROBABILIDAD.**

MEDIDAS DE VARIABILIDAD

La varianza mide desvíos cuadráticos y el desvío devuelve la escala original

1. Varianza σ²(X) — Segundo Momento Centrado (μ2)

Fórmula Operativa:

$\sigma^2(X) = \mu 2 = \sum x_i^2 p_i = m2 - (m1)^2$

$\sigma^2(X) = \int_{MIN}^{MAX} X^2 * f(x)dx - \left[\int_{MIN}^{MAX} X * f(x)dx\right]^2$

Propiedades Principales:

- $\sigma^2(K) = 0$ (La varianza de una constante es nula).
- $\sigma^2(X + K) = \sigma^2(X)$ (Sumar una constante no altera la dispersión).
- $\sigma^2(K * X) = K^2 * \sigma^2(X)$ (Las constantes salen elevadas al cuadrado).

2. Desvío Estándar o Dispersión σ(X)

$\sigma(X) = \sqrt{\sum x_i^2 p_i}$

Solución Dimensional: La varianza queda expresada en unidades al cuadrado (ej: pesos²). El desvío estándar aplica la raíz para recuperar la unidad de medida original de la V.A.

Varianza de la Suma y Covarianza

Varianza de la Suma de Dos V.A.:

$\sigma^2(X + Y) = \sigma^2(X) + \sigma^2(Y) + 2 * Cov(X, Y)$

Concepto de Covarianza Cov(X, Y):
Es la medida del grado de variación conjunta entre dos variables aleatorias X e Y.

Fórmula de Cálculo:

$Cov(X, Y) = \sum x_i * y_j * p_{ij}$

Interpretación de Signo de la Covarianza:

- Cov(X, Y) = 0: Si X e Y son estadísticamente INDEPENDIENTES.
- Cov(X, Y) > 0: Asociación directa (crecen o decrecen juntas).
- Cov(X, Y) < 0: Asociación inversa (una crece cuando la otra disminuye).



VARIABILIDAD RELATIVA

El Coeficiente de Variabilidad estandariza la dispersión comparativa

Fórmula y Propiedad Adimensional del Coeficiente de Variabilidad

$$CV = \sigma(X) / E(X)$$

El Coeficiente de Variabilidad (CV) indica qué proporción representa el desvío estándar respecto de la esperanza matemática. Al ser una medida ADIMENSIONAL (sin unidades), permite comparar la variabilidad relativa de variables con diferentes escalas o unidades de medida.

BAJA VARIABILIDAD

CV < 0.30

- Alta homogeneidad en los datos.
- La esperanza matemática E(X) es fuertemente representativa del conjunto.

MODERADA VARIABILIDAD

0.30 <= CV <= 0.70

- Dispersión intermedia equilibrada.
- Representatividad aceptable de la medida de posición central.

ALTA VARIABILIDAD

CV > 0.70

- Gran heterogeneidad y dispersión.
- Puede superar 1.0 (100%). La E(X) pierde representatividad directa.

MEDIDAS DE FORMA

El tercer momento centrado determina la dirección y sesgo de la distribución

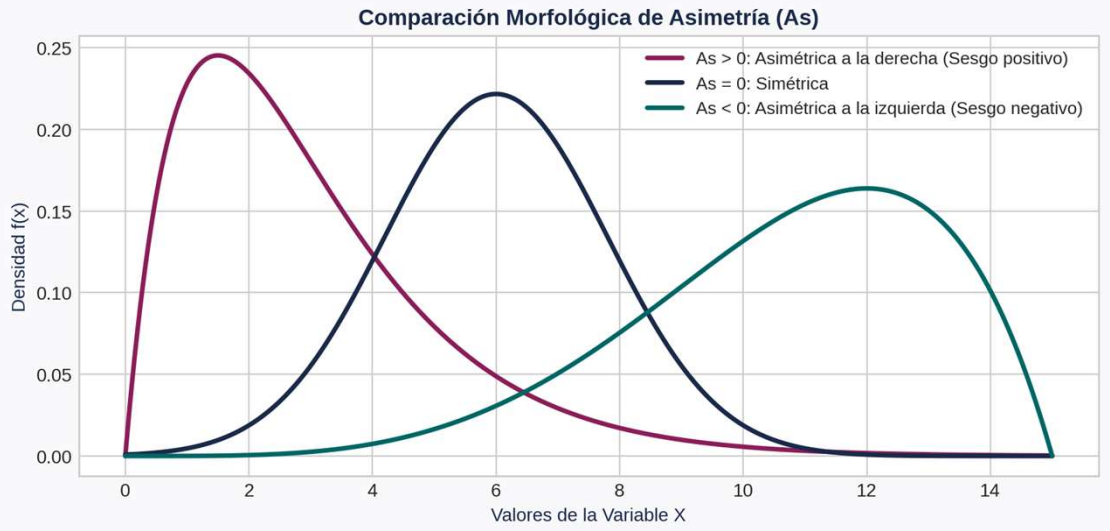
Coeficiente de Asimetría (As)

Fórmula Formal (Basada en μ3):

$$As = \frac{\mu_3}{\sigma^3_{(X)}} = \frac{\sum x_i^3 p_i}{\sigma^3_{(X)}}$$

Criterio de Diagnóstico de Forma:

- As > 0 (Asimetría a la Derecha / Sesgo Positivo):
  La curva presenta una cola derecha alargada. La mayoría de las observaciones se concentran en valores bajos.
- As = 0 (Distribución Simétrica):
  Existe perfecta simetría respecto a E(X). Las colas izquierda y derecha son especulares.
- As < 0 (Asimetría a la Izquierda / Sesgo Negativo):
  La curva presenta una cola izquierda alargada. Las observaciones se concentran en valores altos.



MEDIDAS DE FORMA

El cuarto momento centrado cuantifica el apuntamiento y el peso de las colas

Coeficiente de Kurtosis o Curtosis (K)

Fórmula Formal (Basada en μ4):

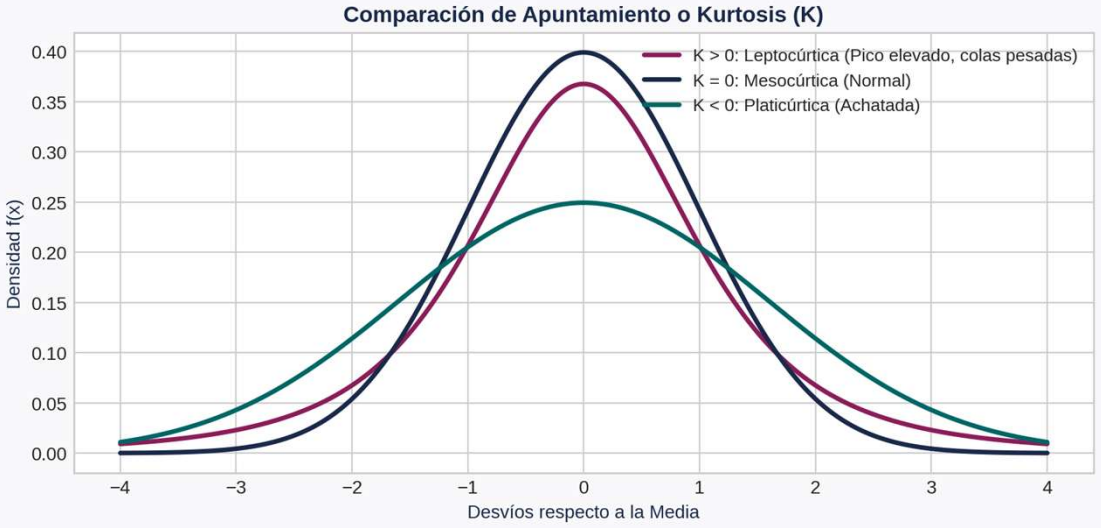
$$K = \frac{\mu_4}{\sigma^4_{(X)}} - 3 = \frac{\sum x_i^4 p_i}{\sigma^4_{(X)}} - 3$$

Clasificación Morfológica de Kurtosis:

• K > 0 (Distribución Leptocúrtica):
Presenta un pico elevado y agudo en el centro con colas pesadas. Alta concentración alrededor de E(X).

• K = 0 (Distribución Mesocúrtica):
Grado de apuntamiento normal (coincide analíticamente con la distribución normal estándar).

• K < 0 (Distribución Platicúrtica):
Presenta una forma achatada y aplanada con colas livianas. Gran dispersión uniforme en el centro.



ESTANDARIZACIÓN DE V.A.

La transformación z escala variables a unidades de desvío estándar respecto a E(X)

Fórmula y Objetivo de la Estandarización

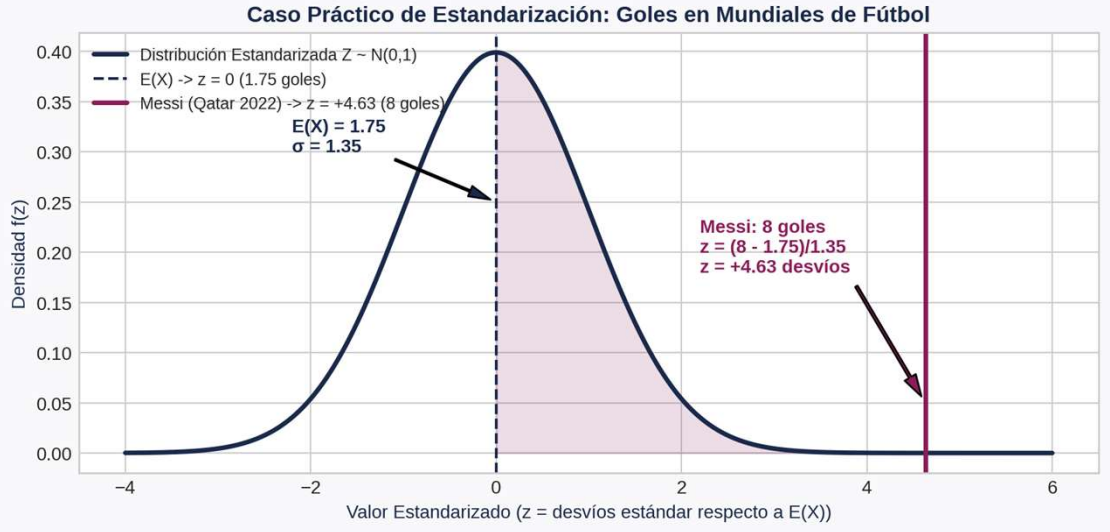
$$z = \frac{X_i - E(X)}{\sigma_{(X)}}$$

Estandarizar implica modificar la unidad de medida para expresarla en términos de desvíos estándar a la izquierda (-) o a la derecha (+) de la esperanza matemática. Permite comparar valores de distintas distribuciones.

Caso Práctico: Futbolistas en Copas del Mundo

- Parámetros de la Población de Futbolistas:
  Esperanza E(X) = 1.75 goles | Desvío Estándar σ(X) = 1.35 goles.
- Desempeño de Messi (Mundial 2026: 8 goles):
  z = (8 - 1.75) / 1.35 = 6.25 / 1.35 = +4.63 desvíos estándar.

Conclusión: El rendimiento de 8 goles se ubica a 4.63 desvíos estándar por encima de la media histórica, evidenciando un desempeño atípico fuera de serie.



SÍNTESIS INTEGRADORA

Cuadro comparativo de operadores y métricas para exploración de datos

Dimensión / Medida	Operador / Fórmula	Interpretación Teórica	Utilidad en Exploración de Datos
Posición: Esperanza E(X)	$E(X) = m_1 = \sum X_i pi$	Promedio a priori al repetir experimentos. Centro de gravedad.	Línea base para modelos predictivos y proyecciones.
Variabilidad: Varianza σ²	$\sigma^2_{(X)} = \mu_2 = \sum x_i^2 p_i$	Dispersión cuadrática de los valores respecto a la E(X).	Medida de riesgo y volatilidad en modelos cuantitativos.
Dispersión: Coef. Var. (CV)	**CV = σ(X) / E(X)**	Variabilidad relativa adimensional. Evalúa representatividad.	Comparación entre variables con distintas escalas.
Forma: Asimetría (As)	**As = μ3 / σ³(X)**	Dirección del sesgo de la curva (Derecha >0, Simétrica =0, Izq <0).	Detección de sesgos en distribuciones de datos reales.
Estandarización: Score z	**z = [Xi - E(X)] / σ(X)**	Distancia en desvíos estándar a la esperanza matemática.	Normalización de atributos para algoritmos de ML.